Universidad Veracruzana

Facultad de Estadística e Informática
Región Xalapa

Licenciatura en Ingeniería en Ciencia de Datos

Análisis de Perfiles de Uso de Inteligencia Artificial en Estudiantes Universitarios mediante el Proceso KDD

Presenta:
Fernández Mendoza Karla Valeria
Hernández Martínez Valentin de Jesús
Morales Garrido Yahyr

Académico:
Lorena López Lozada

Mayo de 2026

"Lis de Veracruz: Arte, Ciencia, Luz"



Contenido

1 Introducción 1
2 Aplicación de la Metodología KDD 1
2.1 Selección de datos 1
2.2 Limpieza y preprocesamiento de datos 1
2.3 Transformación de datos 2
2.4 Minería de datos 2
2.5 Evaluación e interpretación de patrones 3
2.6 Presentación del conocimiento 4
3 Interpretación y Hallazgos Principales 4
4 Conclusión 5
5 Referencias 6

1 Introducción

En el último año, el uso de herramientas de Inteligencia Artificial como ChatGPT o Claude se ha vuelto súper común en las universidades. Lo que empezó como una novedad rápida, hoy forma parte del día a día de muchos estudiantes para hacer sus tareas o estudiar.

Este reporte nace de la necesidad de entender no solo cuántas horas a la semana usamos estas herramientas, sino qué relación hay entre el motivo por el que las usamos, el tiempo que le dedicamos, qué tan satisfechos nos sentimos y cómo influye esto en nuestras calificaciones. Al final, está claro que no todos usamos la IA de la misma manera ni para las mismas cosas.

Por eso, el objetivo de este trabajo es aplicar los pasos del proceso KDD a una base de datos de estudiantes para encontrar perfiles claros de uso y comprender mejor cómo la IA está impactando la vida universitaria.

2 Aplicación de la Metodología KDD

Para realizar este estudio se siguieron los 7 pasos de este proceso:

2.1 Selección de datos

Como fuente principal se utilizó el conjunto de datos *Student AI Tool Usage Dataset*, disponible en la plataforma Kaggle. El análisis se enfocó en estudiantes de licenciatura, seleccionando las variables clave para el estudio: el ID del estudiante, la herramienta de IA utilizada, las horas semanales de uso, el motivo de uso, el nivel de satisfacción y el rendimiento académico reportado.

2.2 Limpieza y preprocesamiento de datos

El proceso de limpieza se dividió en dos etapas complementarias para asegurar la calidad y consistencia del conjunto de datos antes del análisis:

Preprocesamiento en OpenRefine:

En primer lugar, se utilizó OpenRefine para estandarizar el texto y organizar la estructura inicial de la base de datos. En esta herramienta se realizaron los siguientes ajustes:

- **Estandarización y traducción:** Se renombraron los encabezados de las variables por términos más cortos e intuitivos y se tradujeron las categorías del inglés al español (por ejemplo, adaptando los motivos de uso como Study a Estudiar y Coding a Codificación).
- **Reorganización de identificadores:** Se reasignaron los identificadores (ID) de los estudiantes a una secuencia numérica continua del 1 al 199 para simplificar el manejo de las observaciones.
- **Agrupamiento cualitativo:** En la columna de comentarios, se agruparon las respuestas de texto libre con significados similares para reducir el ruido y sintetizar las opiniones.
- **Eliminación de celdas vacías:** Se filtraron y eliminaron todos los registros que presentaban valores faltantes en las variables principales.

- **Filtrado y validación en R:**

Posteriormente, dentro del entorno R se aplicó el criterio de control de calidad kdd_complete_case == 1. Con esta regla se excluyeron 12 registros adicionales que, a pesar de estar completos, presentaban inconsistencias de captura o valores atípicos extremos (como el reporte irrealista de un consumo superior a 70 horas semanales de IA).

Como resultado de ambas etapas de limpieza, la muestra inicial de 199 observaciones termino en una base de datos final de $N = 187$ registros limpios y confiables para la fase de modelado.

2.3 Transformación de datos

Para que los algoritmos pudieran procesar la información correctamente, los datos se prepararon mediante dos pasos principales:

- **Codificación binaria (One-Hot Encoding):** Como los algoritmos matemáticos no entienden directamente palabras o categorías (como "Estudiar" o "Programar"), la variable del motivo de uso se convirtió en columnas de ceros y unos (0 y 1). Así, si un alumno usaba la IA para estudiar, la columna uso_Estudiar tomaba el valor de 1 y las demás el de 0.
- **Estandarización Z-score:** Las variables numéricas tienen escalas muy distintas; por ejemplo, el nivel de satisfacción va de 1 a 5, mientras que el rendimiento académico va de 60 a 100. Si se dejaran los datos en su escala original, las calificaciones dominarían la ecuación por tener números más grandes. Con la estandarización, todas las variables numéricas se ajustaron a una misma escala (con media de 0 y desviación estándar de 1), evitando que unas variables pesen más que otras al calcular la similitud entre estudiantes.

2.4 Minería de datos

En esta etapa se aplicó el algoritmo de agrupamiento no supervisado K-Means, el cual sirve para encontrar patrones ocultos y agrupar automáticamente a los estudiantes que tienen respuestas o comportamientos similares.

Dado que al inicio no se sabía cuál era la cantidad ideal de grupos para organizar a los alumnos, en el código de R se realizó un experimento probando diferentes opciones de agrupamiento, desde $k = 2$ hasta $k = 6$ grupos. Para evaluar cuál de estas opciones era la mejor, se utilizó una prueba matemática llamada Coeficiente de Silueta. Esta métrica mide dos cosas esenciales:

- **Cohesión:** Que los estudiantes dentro de un mismo grupo se parezcan mucho entre sí.
- **Separación:** Que un grupo sea claramente diferente de los demás.

El objetivo de esta evaluación fue encontrar el número de grupos (k) que obtuviera la puntuación de silueta más alta, garantizando una división limpia, lógica y con sentido para el estudio.

2.5 Evaluación e interpretación de patrones

Para determinar cuántos perfiles debían formarse, se realizó una evaluación iterativa probando diferentes cantidades de grupos desde $k = 2$ hasta $k = 6$. Para medir qué tan bien hecha estaba cada división, se utilizó el Coeficiente de Silueta, una métrica matemática que otorga valores en una escala del -1 al 1, donde los números más altos indican que los grupos están mejor definidos y organizados.

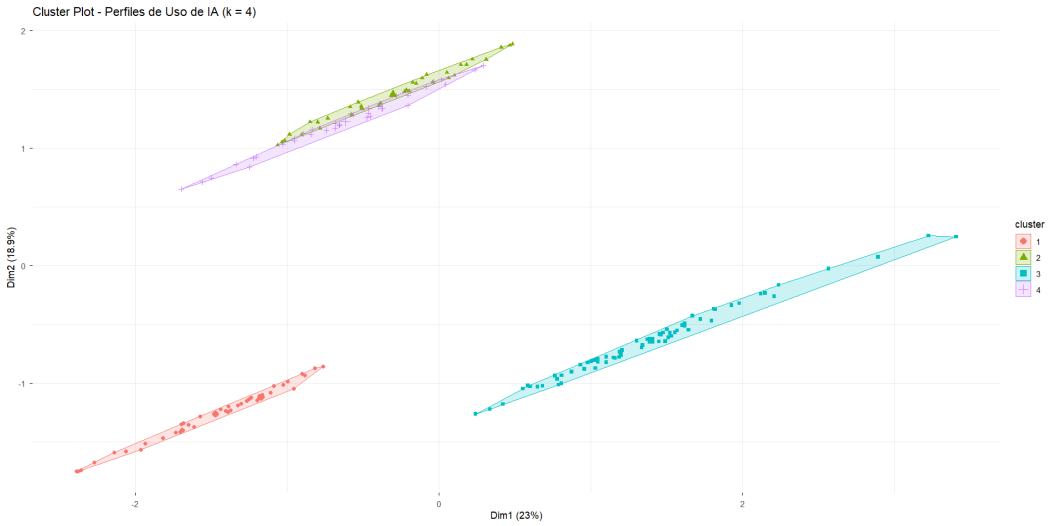
Como se observa en la Tabla 1, la partición correspondiente a $k = 4$ obtuvo el puntaje más alto de todo el experimento con 0.4457, superando con claridad al resto de los escenarios.

Tabla 1: Evaluación de las particiones mediante el Coeficiente de Silueta

Cantidad de Grupos (k)	Coeficiente de Silueta Promedio	Descripción del Resultado
$k = 2$	0.2393	Grupos poco claros o débiles
$k = 3$	0.3432	Separación aceptable
$k = 4$	0.4457	La mejor opción (Grupos bien definidos y separados)
$k = 5$	0.3792	Disminuye la claridad de los grupos
$k = 6$	0.3699	Los grupos se empiezan a encimar o confundir

Además, se eligió este número, ya que, si se hubieran elegido menos grupos como $k = 2$ o 3 se habría obligado a juntar a estudiantes con formas de trabajar muy distintas en un mismo grupo, haciendo que las divisiones fueran confusas. Por el contrario, si se hubieran elegido más grupos como $k = 5$ o 6, el algoritmo habría intentado separar a alumnos que en realidad comparten el mismo perfil. Por lo tanto, trabajar con 4 grupos demostró ser el punto exacto de equilibrio para obtener perfiles limpios y fáciles de interpretar.

Como prueba visual de esta evaluación, la siguiente gráfica muestra cómo se distribuyen y separan los cuatro grupos en el espacio, confirmando que la partición es limpia y que los perfiles están claramente delimitados:



2.6 Presentación del conocimiento

Para concluir el proceso de KDD, los resultados del análisis se tradujeron en cuatro perfiles de estudiantes muy claros. Esto permite ver fácilmente cómo se relacionan el tiempo que dedican a usar IA, su nivel de satisfacción y sus calificaciones dentro del grupo de alumnos analizado.

Tabla 2: Perfiles identificados de estudiantes según su uso de IA

Cluster	Total de Estudiantes	Horas Semanales Promedio	Satisfacción Promedio (Escala 1-5)	Rendimiento Académico Promedio	Motivo Principal de Uso
1	43	7.05 hrs	4.14	76.7	Escribir
2	36	8.08 hrs	3.75	77.3	Investigación
3	70	8.37 hrs	3.63	78.4	Estudiar
4	38	7.32 hrs	3.87	78.2	Codificación

3 Interpretación y Hallazgos Principales

A partir del análisis de los datos, se identificaron cuatro perfiles claros de estudiantes universitarios según su interacción con las herramientas de Inteligencia Artificial. Lejos de ser un grupo homogéneo, los alumnos se dividen en comportamientos muy particulares:

- **Perfil enfocado en la redacción (Cluster 1: 43 alumnos):** Dedican un promedio de 7.05 horas semanales a la IA y destacan por tener el nivel de satisfacción más

alto que es de 4.14 de 5. Son estudiantes que encuentran en estas herramientas un apoyo sumamente útil para redactar, estructurar y pulir textos académicos.

- **Perfil enfocado en la investigación (Cluster 2: 36 alumnos):** Invierten más tiempo en la exploración, registrando un promedio de 8.08 horas semanales. Su enfoque principal es buscar información, contrastar datos y profundizar en temas complejos para sus materias.
- **Perfil enfocado en el estudio general (Cluster 3: 70 alumnos):** Es el grupo más numeroso, ya que, representa más de un tercio de la muestra. Destacan por dedicar la mayor cantidad de tiempo a la semana con 8.37 horas y obtienen el rendimiento académico promedio más alto con 78.4. Utilizan la IA principalmente como una herramienta de apoyo cotidiano para repasar, comprender conceptos y estudiar.
- **Perfil enfocado en la programación (Cluster 4: 38 alumnos):** Invierten 7.32 horas semanales y su motivación principal es la codificación. Utilizan la IA como un asistente técnico para resolver errores de código, programar y desarrollar proyectos de ingeniería o ciencia de datos.

4 Conclusión

El desarrollo de este proceso KDD permitió analizar de manera estructurada el comportamiento de los estudiantes universitarios frente al uso de herramientas de Inteligencia Artificial. A través de la implementación del algoritmo K-Means y su respectiva validación matemática mediante el Coeficiente de Silueta, fue posible demostrar que los alumnos no utilizan la tecnología de forma idéntica, sino que se agrupan en cuatro perfiles bien definidos.

A partir de esto, los puntos más destacables son:

- **Diversidad de uso:** La IA se ha integrado a la vida académica de formas muy distintas, abarcando desde el apoyo general para el estudio cotidiano hasta usos más especializados como la redacción, la investigación y la programación.
- **Impacto en el rendimiento:** Se identificó que las comunidades de estudiantes que dedican un mayor número de horas semanales a estas herramientas, particularmente en tareas de estudio general, reflejan un promedio de rendimiento académico competitivo dentro de la muestra evaluada.

En conclusión, este trabajo cumplió con el objetivo de transformar datos crudos en conocimiento útil, ofreciendo un panorama claro de cómo las nuevas tecnologías están moldeando las dinámicas de aprendizaje y productividad de los universitarios.

5 Referencias

- Baloch, M. Z. (2025). *Student AI Tool Usage Dataset* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/zohairbaloch/student-ai-tool-usage-dataset
- Maimon, Oded & Rokach, Lior. (2005). Chapter 1 - Introduction to Knowledge Discovery in Databases. https://www.researchgate.net/publication/225835494_Chapter_1_-_Introduction_to_Knowledge_Discovery_in_Databases
- IBM. (s. f.). *¿Qué es K-Means clustering?* IBM Think. Recuperado de https://www.ibm.com/think/topics/k-means-clustering
- Elsevier. (s. f.). *Silhouette coefficient*. ScienceDirect Topics. Recuperado el 17 de septiembre de 2026, de https://www.sciencedirect.com/topics/computer-science/silhouette-coefficient
- Google. (2026). *Gemini* (versión de septiembre de 2026) [Modelo de lenguaje grande]. https://gemini.google.com