

Facultad de Estadística e Informática
Región Xalapa

Licenciatura en Ingeniería en Ciencia de Datos

Análisis de Perfiles de Uso de Inteligencia Artificial en Estudiantes Universitarios mediante la metodología CRISP-DM

Presenta:
Fernández Mendoza Karla Valeria
Hernández Martínez Valentin de Jesús
Morales Garrido Yahyr

Académico:
Lorena López Lozada

Septiembre de 2026

"Lis de Veracruz: Arte, Ciencia, Luz"



Contenido

1 Introducción 1
2 Aplicación de la metodología CRISP-DM 1
2.1 Comprensión del negocio 1
2.2 Comprensión de los datos 1
2.3 Preparación de los datos 2
2.4 Modelado 2
2.5 Evaluación 2
2.6 Despliegue 3
3 Interpretación y hallazgos principales 3
4 Conclusión 4
5 Referencias 5

1 Introducción

En el último año, la integración de herramientas de Inteligencia Artificial como ChatGPT o Claude se ha convertido en una práctica cotidiana dentro del ámbito universitario. Hoy en día, los estudiantes recurren a estas tecnologías como apoyo en sus actividades académicas, abarcando desde la investigación y la redacción de textos hasta la programación y el estudio diario.

Este análisis busca profundizar en dicho fenómeno, explorando no solo la frecuencia semanal de uso, sino también los propósitos específicos, el nivel de satisfacción de los usuarios y su relación con el rendimiento académico.

Bajo este contexto, el presente trabajo tiene como objetivo aplicar la metodología CRISP-DM a una base de datos de estudiantes con el fin de identificar perfiles de uso mediante el algoritmo K-Means. De este modo, se pretende transformar los datos crudos en conocimiento útil para comprender la diversidad de comportamientos presentes en la muestra.

2 Aplicación de la metodología CRISP-DM

El desarrollo de este análisis se estructuró a partir de las seis fases tradicionales de la metodología CRISP-DM: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. Específicamente, dentro de la etapa de modelado, se implementó el algoritmo K-Means con el propósito de segmentar a los estudiantes en grupos con características y patrones de comportamiento afines.

2.1 Comprensión del negocio

El problema consiste en conocer si los estudiantes pueden agruparse en perfiles de acuerdo con su forma de utilizar las herramientas de IA. La base contiene información sobre la herramienta utilizada, las horas semanales de uso, el motivo de uso, el nivel de satisfacción y el rendimiento académico

El objetivo principal es identificar grupos de estudiantes que presenten características parecidas y describirlos de una forma sencilla. Con ello se pretende obtener una visión general de los distintos perfiles de uso de Inteligencia Artificial presente en los datos.

El análisis no parte de grupos definidos previamente. Los perfiles serán obtenidos a partir de los patrones que encuentre el algoritmo K-Means.

2.2 Comprensión de los datos

Para llevar a cabo este estudio se utilizó el conjunto de datos denominado *Student AI Tool Usage Dataset*. En esta etapa se exploró la información disponible con el propósito de entender su estructura y comprobar que las variables seleccionadas fueran las adecuadas para el análisis.

Las variables consideradas incluyeron el identificador del estudiante (*ID*), la herramienta de inteligencia artificial utilizada, las horas semanales de dedicación, el propósito principal del uso, el nivel de satisfacción, el rendimiento académico y una variable de control para identificar los casos completos (*kdd_complete_case*).

El conjunto de datos inicial contaba con un total de 199 observaciones. Durante la revisión y el filtrado de la información, se excluyeron aquellos registros que presentaban inconsistencias de captura o valores atípicos extremos (como reportes poco realistas de más de 70 horas semanales de uso). Tras este proceso de depuración, se estableció una base de datos final de 187 registros limpios y confiables para avanzar hacia las siguientes etapas del modelo.

2.3 Preparación de los datos

En esta fase se preparó la información para que pudiera ser utilizada por K-Means. Primero se seleccionaron las variables necesarias y se revisaron las categorías de la variable de uso. Los nombres en inglés fueron unificados con sus equivalentes en español, por ejemplo, Study con Estudiar, Coding con Codificación, Writing con Escribir y Research con Investigación.

Después se conservaron únicamente los registros con kdd_complete_case igual a 1 y se eliminaron las filas que todavía presentaran información faltante. Este procedimiento permitió trabajar con los registros completos que se utilizarían en el agrupamiento.

Como la variable uso contiene categorías de texto, se transformó en columnas de valores 0 y 1 mediante One-Hot Encoding. Esto permite incorporar el motivo de uso al análisis de una forma que pueda ser utilizada por el algoritmo.

Finalmente, las variables seleccionadas para el agrupamiento fueron estandarizadas mediante la escala Z-score. De esta forma, las variables quedaron en una escala comparable antes de calcular las similitudes entre estudiantes.

2.4 Modelado

Una vez preparados los datos se aplicó el algoritmo K-Means, una técnica que permite formar grupos de observaciones con características similares. En este caso, cada estudiante fue asignado a un grupo de acuerdo con las variables utilizadas en el análisis.

Para decidir cuántos grupos utilizar, el código probó diferentes opciones, desde k = 2 hasta k = 6. Para cada una se calculó el Coeficiente de Silueta, que permite observar qué tan parecidos son los estudiantes dentro de un mismo grupo y qué tan separados están de los demás.

Con base en los resultados del análisis, se utilizó k = 4 para el modelo final. El código de R asignó a cada estudiante un número de cluster y posteriormente calculó los promedios de horas de uso, satisfacción y rendimiento, además del motivo principal de uso.

2.5 Evaluación

Para evaluar las diferentes agrupaciones se utilizó el Coeficiente de Silueta. Esta medida toma valores entre -1 y 1 y permite conocer qué tan bien separados están los grupos. Un valor más alto indica una agrupación más clara.

Cantidad de grupos (k)	Coeficiente de silueta	Descripción
2	0.2393	Grupos pocos claros o débiles
3	0.3432	Separación aceptable

4	0.4457	Grupos mejor definidos y separados
5	0.3792	Disminuye la claridad de los grupos
6	0.3699	Los grupos comienzan a encimarse

El valor más alto correspondió a k=4, con un Coeficiente de Silueta de 0.4457. Por esta razón, el modelo final se trabajo con cuatro grupos.

2.6 Despliegue

En la última fase, los resultados del modelo se transformaron en perfiles que pueden entenderse fácilmente. Para cada cluster se calculó el número de estudiantes, las horas promedio de uso, la satisfacción promedio, el rendimiento académico promedio y el motivo principal de uso.

Clúster	Estudiantes	Horas promedio	Satisfacción	Rendimiento	Motivo principal
1	43	7.05 hrs	4.14	76.7	Escribir
2	36	8.08 hrs	3.75	77.3	Investigación
3	70	8.37 hrs	3.63	78.4	Estudiar
4	38	7.32 hrs	3.87	78.2	Codificación

La tabla resume los perfiles obtenidos en el análisis.

3 Interpretación y hallazgos principales

A partir de los cuatro grupos obtenidos, se pueden observar perfiles diferentes de estudiantes según su interacción con las herramientas de Inteligencia Artificial.

- **Perfil enfocado en la redacción (Cluster 1: 43 estudiantes):** Dedican un promedio de 7.05 horas semanales a la IA y presentan el nivel de satisfacción más alto, con 4.14 de 5. Su principal motivo de uso es escribir.
- **Perfil enfocado en la investigación (Cluster 2: 36 estudiantes):** Registran un promedio de 8.08 horas semanales. Su principal motivo de uso es la investigación y presentan un rendimiento académico promedio de 77.3.
- **Perfil enfocado en el estudio general (Cluster 3: 70 estudiantes):** Es el grupo más numeroso. Presenta el mayor promedio de horas semanales, con 8.37, y el rendimiento académico promedio más alto, con 78.4. Su principal motivo de uso es estudiar.
- **Perfil enfocado en la programación (Cluster 4: 38 estudiantes):** Presenta 7.32 horas semanales en promedio y su principal motivo de uso es la codificación. Su rendimiento académico promedio es de 78.2.

Estos resultados muestran que los estudiantes no utilizan la Inteligencia Artificial de una sola manera. Existen diferentes formas de aprovechar estas herramientas, desde la redacción y la investigación hasta el estudio y la programación.

4 Conclusión

La aplicación de la metodología CRISP-DM permitió organizar el análisis del uso de Inteligencia Artificial en estudiantes universitarios desde la definición del problema hasta la presentación de los resultados. La preparación de los datos permitió contar con información adecuada para aplicar K-Means y comparar diferentes cantidades de grupos.

El análisis permitió identificar cuatro perfiles de estudiantes. Cada uno presenta características diferentes en cuanto a las horas de uso, el nivel de satisfacción, el rendimiento académico y el motivo principal para utilizar Inteligencia Artificial.

El perfil de redacción presentó la satisfacción promedio más alta, mientras que el perfil de estudio general fue el grupo más numeroso y registró los promedios más altos de horas de uso y rendimiento académico dentro de los grupos identificados.

En conclusión, el uso de K-Means dentro de CRISP-DM permitió transformar los datos disponibles en perfiles fáciles de interpretar, ofreciendo una visión más clara de las diferentes formas de uso de Inteligencia Artificial entre los estudiantes.

5 Referencias

- Baloch, M. Z. (2025). *Student AI Tool Usage Dataset* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/zohairbaloch/student-ai-tool-usage-dataset
- IBM. (s. f.). *Conceptos básicos de ayuda de CRISP-DM*. IBM SPSS Modeler. Recuperado el 22 de septiembre de 2026, de https://www.ibm.com/docs/es/spss-modeler/saas?topic=dm-crisp-help-overview