Universidad Veracruzana

Facultad de Estadística e Informática
Región Xalapa

Licenciatura en Ingeniería en Ciencia de Datos

Análisis y predicción de la demanda eléctrica en México mediante la metodología SEMMA.

Presenta:
Fernández Mendoza Karla Valeria
Hernández Martínez Valentin de Jesús
Morales Garrido Yahyr

Académico:
Lorena López Lozada

Septiembre de 2026

"Lis de Veracruz: Arte, Ciencia, Luz"



Contenido

1 Introducción 1
2 Objetivos 1
2.1 Objetivo general 1
2.2 Objetivos específicos 1
3 Descripción de los datos 1
4 Aplicación de Metodología SEMMA 1
4.1 Sample (Muestreo) 1
4.2 Explore (Exploración) 2
4.3 Modify (Modificación) 3
4.4 Model (Modelado) 3
4.5 Asses (Evaluación de resultados) 3
5 Conclusión 5
6 Código 6
7 Referencias 9

1 Introducción

El consumo de energía eléctrica es un factor fundamental en prácticamente todas las actividades económicas y cotidianas. Comprender cómo se comporta esta demanda es esencial para la correcta administración y distribución de los recursos energéticos.

El presente reporte tiene como propósito analizar el comportamiento de la demanda eléctrica y proponer un modelo de predicción, aplicando la metodología de minería de datos conocida como SEMMA (por sus siglas en inglés: Sample, Explore, Modify, Model, Assess). A través de este enfoque, se busca transformar los datos sin procesar en conocimiento útil, de manera estructurada y formal, para entender las variaciones del consumo eléctrico y pronosticar valores futuros basándose en variables clave.

2 Objetivos

2.1 Objetivo general

Aplicar las cinco fases de la metodología SEMMA para analizar los datos de consumo eléctrico y desarrollar un modelo predictivo eficiente.

2.2 Objetivos específicos

- Describir y explorar la base de datos para detectar patrones relevantes de consumo.
- Preparar y particionar los datos en conjuntos de entrenamiento y prueba para asegurar la validez del modelo.
- Implementar un algoritmo de aprendizaje automático adecuado para realizar las predicciones.

3 Descripción de los datos

La información utilizada para este proyecto proviene de los datos publicados por el Centro Nacional de Control de Energía (CENACE), los cuales contienen observaciones horarias reales del comportamiento eléctrico durante el año 2025 para dos zonas geográficas distintas: la región Central (CEN) y la región Peninsular (PEN). Dentro de este conjunto de datos, las variables más relevantes para el estudio incluyen:

- **ÁREA:** Identifica si el registro pertenece a la región CEN o PEN.
- **HORA:** Momento exacto del día en formato de 24 horas.
- **GENERACIÓN e IMPORTACIÓN:** Cantidad de energía eléctrica producida e importada en la región (en MWh).
- **DEMANDA:** Variable objetivo del análisis, que representa el consumo total de energía eléctrica registrado en esa hora específica (en MWh).

4 Aplicación de Metodología SEMMA

4.1 Sample (Muestreo)

La fase inicial de la metodología se enfoca en extraer una muestra representativa de la información. Para garantizar una evaluación objetiva y evitar que el modelo sea probado con los mismos datos que utiliza para aprender, se llevó a cabo una partición aleatoria del

conjunto principal. De esta forma, el 70% de los registros se destinó al "conjunto de entrenamiento", que son datos que el algoritmo usa para aprender los patrones.

El 30% restante se reservó como "conjunto de prueba", actuando como información para medir la precisión real del modelo. Esta práctica resulta fundamental para prevenir el sobreajuste y asegurar que las predicciones sean confiables y efectivas al enfrentarse a nuevos escenarios.

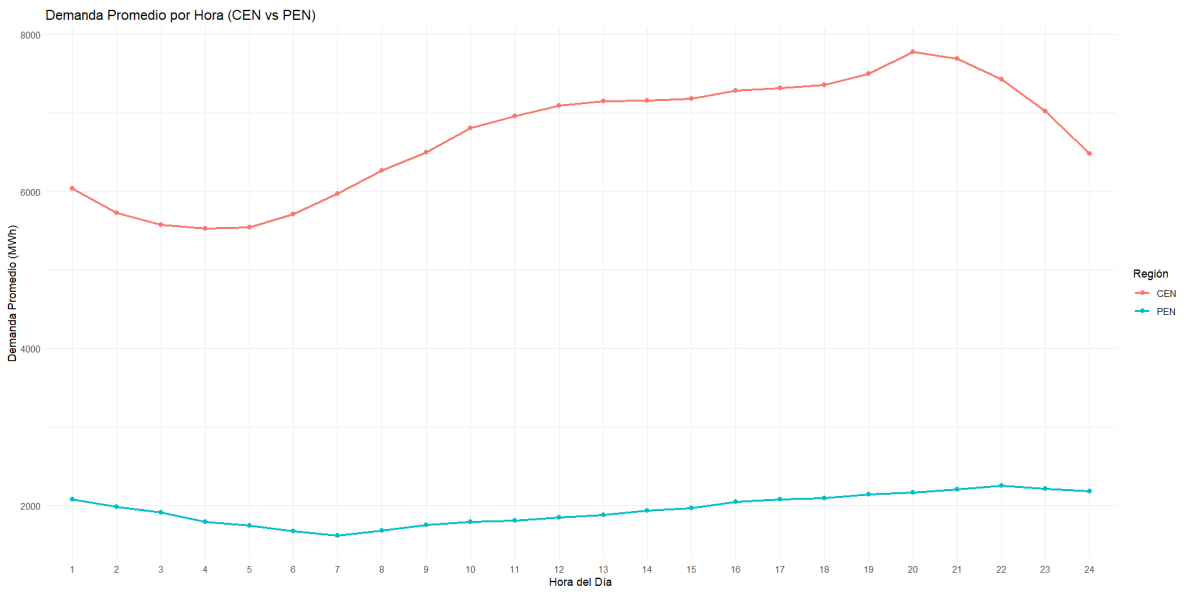
4.2 Explore (Exploración)

En la fase de exploración, se llevó a cabo un análisis descriptivo con el objetivo de comprender el comportamiento de los datos. A través de este procedimiento, se observó que la demanda eléctrica presenta variaciones significativas a lo largo del día. En particular, los niveles mínimos de consumo suelen registrarse durante la madrugada, frecuentemente entre las 4:00 y las 5:00 horas. Por el contrario, los picos de máxima demanda ocurren en horario nocturno, concentrándose de manera específica entre las 20:00 y las 21:00 horas, un intervalo que coincide con el incremento simultáneo del uso de energía en los sectores residencial y comercial.

Tabla 1. Estadísticas descriptivas de la demanda

Área	Promedio	Mínimo	Máximo	Desv. estándar
CEN	6709	3892	8481	881
PEN	1955	128	2958	361

Gráfica 1. Demanda promedio por hora



Como se observa en la Tabla 1 y la Gráfica 1, existe una diferencia significativa en la escala de consumo entre ambas zonas. La región Central (CEN) concentra una demanda eléctrica considerablemente mayor, con un promedio de 6,709 MWh y picos que superan los 8,400 MWh, lo cual contrasta fuertemente con la región Peninsular (PEN), cuyo consumo es mucho menor y más estable. A pesar de esta diferencia, la gráfica demuestra que ambas regiones comparten un patrón de comportamiento diario muy similar: la

demanda desciende a sus niveles mínimos durante las primeras horas de la madrugada y experimenta un incremento sostenido a lo largo del día, alcanzando su punto máximo durante la noche (alrededor de las 20:00 horas).

4.3 Modify (Modificación)

Durante la fase de modificación, los datos fueron preparados y estructurados para asegurar su correcta interpretación por parte del algoritmo predictivo. Inicialmente, se verificó la ausencia de valores nulos o faltantes que pudieran comprometer la calidad del análisis. Posteriormente, variables como el "ÁREA" y la "HORA" se transformaron a un formato categórico (factores). Esta conversión es fundamental ya que el horario no representa una magnitud matemática progresiva (es decir, las 20:00 horas no son numéricamente mayores que las 5:00 horas en este contexto), sino que actúan como etiquetas temporales independientes que influyen de manera específica en los patrones de consumo eléctrico.

4.4 Model (Modelado)

Para el modelado de la demanda, y aprovechando la estructura de la información, se seleccionó el algoritmo de Bosques Aleatorios (Random Forest). Este es un método robusto de aprendizaje supervisado que construye múltiples árboles de decisión durante la fase de entrenamiento y unifica sus resultados para generar una predicción más precisa. Se eligió esta técnica debido a su excelente capacidad para capturar relaciones complejas y no lineales (como las fluctuaciones del consumo a lo largo del día según la región geográfica), superando frecuentemente el desempeño de los métodos estadísticos tradicionales. El algoritmo fue entrenado utilizando el 70% de los datos previamente separados, configurándose para predecir la DEMANDA en función de la HORA, el ÁREA y la GENERACIÓN.

4.5 Asses (Evaluación de resultados)

Durante la fase de evaluación, se midió la eficacia del modelo de Bosques Aleatorios aplicándolo al conjunto de prueba, equivalente al 30% de los datos que el algoritmo no había procesado previamente. Se compararon las predicciones generadas frente a los valores reales de demanda para determinar su precisión. El análisis de las métricas de desempeño arrojó un Error Cuadrático Medio (RMSE) de aproximadamente 379.25 y un Error Absoluto Medio (MAE) de 291.01. Adicionalmente, el modelo alcanzó un coeficiente de determinación (R-cuadrado) de 0.976, lo que indica que es capaz de explicar más del 97% de la variabilidad en el consumo eléctrico, demostrando ser altamente competente para estimar la demanda en diferentes horarios y regiones.

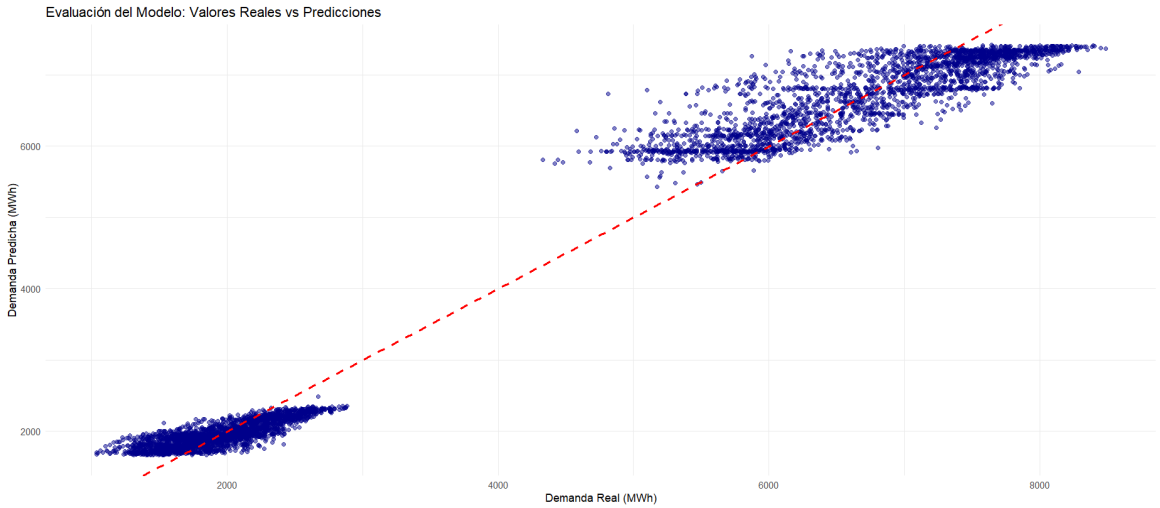
Tablas 2. Métricas de Desempeño del Modelo

RMSE	Rsquared	MAE
379.2536625	0.9766804	291.0122565

Como se ve en la gráfica de dispersión, existe una fuerte alineación entre los valores predichos por el modelo y la demanda real. La concentración de los puntos a lo largo de la línea diagonal de referencia (en color rojo) evidencia visualmente la alta precisión de

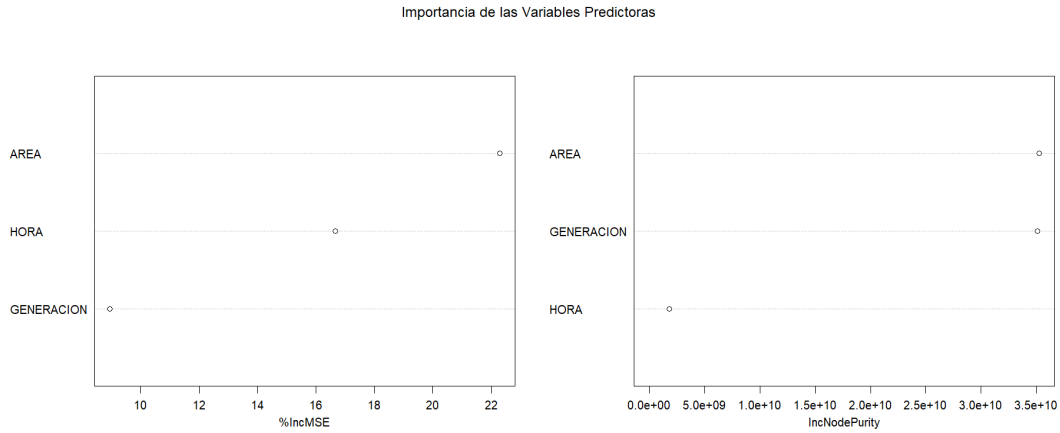
las estimaciones, confirmando que el algoritmo logra ajustarse adecuadamente tanto a los periodos de bajo consumo como a los picos de mayor demanda.

Gráfica 2. Valores reales vs. Predicciones



Por otro lado, el análisis de la importancia de las variables predictoras revela que el "ÁREA" y el nivel de "GENERACIÓN" son los factores más determinantes para que el modelo logre estimar el consumo correctamente. La "HORA" del día, aunque es relevante para capturar el ciclo diario, presenta una influencia comparativamente menor en la estructura de decisión del modelo frente a las otras variables.

Gráfica 3. Importancia de las variables predictoras



5 Conclusión

La implementación de la metodología SEMMA resultó ser una estrategia sumamente efectiva para estructurar y ejecutar el análisis de la demanda eléctrica. A través de este proceso sistemático, fue posible transformar datos sin procesar del CENACE en conocimiento de gran utilidad, identificando que el consumo energético presenta patrones altamente predecibles que se encuentran fuertemente asociados a la ubicación geográfica y a la hora del día.

La partición adecuada de la información y la posterior aplicación del algoritmo de Bosques Aleatorios (Random Forest) confirmaron la capacidad de las técnicas de aprendizaje automático para encontrar relaciones complejas y no lineales entre las variables. Con un coeficiente de determinación superior al 97%, el modelo demostró una alta precisión predictiva al evaluarse con información inédita. Finalmente, este análisis subraya el valor de la minería de datos como una herramienta clave para identificar asociaciones y anticipar el comportamiento del consumo, lo cual resulta indispensable para optimizar la distribución de los recursos y apoyar la toma de decisiones estratégicas en el sector energético.

6 Código

```
# ANÁLISIS DE DEMANDA ELÉCTRICA: METODOLOGÍA SEMMA

install.packages("caret")
install.packages("prodlim")
library(caret)        # Para dividir datos (Sample) y métricas (Assess)
install.packages("randomForest")
library(randomForest) # Para nuestro modelo de Machine Learning (Model)
library(ggplot2)      # Para gráficas (Explore)
library(dplyr)        # Para manipulación de datos (Modify)



# 1. S - SAMPLE (Muestreo)
# Dividimos los datos aleatoriamente: 70% Entrenamiento, 30% Prueba
set.seed(123) # Se usa una semilla para que el resultado siempre sea replicable

indice_entrenamiento <- createDataPartition(datos$DEMANDA, p = 0.7, list = FALSE)
datos_entrenamiento <- datos[indice_entrenamiento, ]
datos_prueba <- datos[-indice_entrenamiento, ]

# 2. E - EXPLORE (Exploración)
estadisticas_descriptivas <- datos_entrenamiento %>%
  group_by(AREA) %>%
  summarise(
    Promedio = mean(DEMANDA),
    Minimo = min(DEMANDA),
    Maximo = max(DEMANDA),
    Desviacion_Estandar = sd(DEMANDA)
  )
print("=== Estadísticas Descriptivas por Región ===")
```

```
print(estadisticas_descriptivas)


datos_promedio_hora <- datos_entrenamiento %>%
  group_by(HORA, AREA) %>%
  summarise(Demanda_Promedio = mean(DEMANDA), .groups = 'drop')


grafica_promedio <- ggplot(datos_promedio_hora, aes(x = factor(HORA), y =
Demanda_Promedio, color = AREA, group = AREA)) +
  geom_line(linewidth = 1) +
  geom_point(size = 2) +
  labs(title = "Demanda Promedio por Hora (CEN vs PEN)",
       x = "Hora del Día",
       y = "Demanda Promedio (MWh)",
       color = "Región") +
  theme_minimal()
print(grafica_promedio)


# 3. M - MODIFY (Modificación)
print(paste("Cantidad de datos nulos en entrenamiento:",
sum(is.na(datos_entrenamiento))))


datos_entrenamiento <- datos_entrenamiento %>%
  mutate(
    AREA = as.factor(AREA),
    HORA = as.factor(HORA)
  )


datos_prueba <- datos_prueba %>%
  mutate(
    AREA = as.factor(AREA),
    HORA = as.factor(HORA)
```

```
  )

# 4. M - MODEL (Modelado)
modelo_rf <- randomForest(DEMANDA ~ HORA + AREA + GENERACION,
                          data = datos_entrenamiento,
                          ntree = 100,
                          importance = TRUE)

# 5. A - ASSESS (Evaluación de Resultados)
varImpPlot(modelo_rf, main = "Importancia de las Variables Predictoras")

predicciones <- predict(modelo_rf, newdata = datos_prueba)
metricas_desempeno <- postResample(pred = predicciones, obs =
datos_prueba$DEMANDA)
print("=== Métricas de Desempeño del Modelo ===")
print(metricas_desempeno)

datos_resultados <- data.frame(Real = datos_prueba$DEMANDA, Predicho =
predicciones)

grafica_dispersion <- ggplot(datos_resultados, aes(x = Real, y = Predicho)) +
  geom_point(alpha = 0.5, color = "darkblue") +
  geom_abline(intercept = 0, slope = 1, color = "red", linetype = "dashed", linewidth =
1) +
  labs(title = "Evaluación del Modelo: Valores Reales vs Predicciones",
       x = "Demanda Real (MWh)",
       y = "Demanda Predicha (MWh)") +
  theme_minimal()
print(grafica_dispersion)
```

7 Referencias

Centro Nacional de Control de Energía. (s.f.). *Sistema de Información de Mercado*. Gobierno de México. https://www.cenace.gob.mx/

Chumbar, S. (s.f.). SEMMA methodology in data mining: A deep dive. *Medium*. https://medium.com/@shawn.chumbar/semma-methodology-in-data-mining-a-deep-dive-c8874cb4239