Universidad Veracruzana

**Facultad de Estadística e Informática**
**Región Xalapa**

Licenciatura en Ingeniería en Ciencia de Datos

# Observatorio de riesgo vial de Xalapa: pronóstico de accidentes de tránsito

Metodología de la Investigación

Presenta:
**Méndez Lara Vanessa Guadalupe**
**Rivera Baez Vanessa Lizeth**

Académico:
**Lorena López Lozada**

Octubre de 2026

"Lis de Veracruz: Arte, Ciencia, Luz"



# Resumen

Los accidentes de tránsito son un problema cotidiano en Xalapa, Veracruz, pero no existe una herramienta pública que permita anticipar cuántos ocurrirán en los próximos meses. En este trabajo aplicamos la metodología TDSP (Team Data Science Process) para construir la primera versión de un observatorio de riesgo vial. Utilizamos datos abiertos del INEGI sobre accidentes de tránsito en Xalapa de 2015 a 2025 (23,897 accidentes en total). En la exploración de los datos encontramos cambios de nivel abruptos en la serie, probablemente asociados a cambios en el registro, y observamos que los accidentes se concentran de lunes a viernes entre las 8 y 9 h y entre las 14 y 15 h. Comparamos siete modelos de pronóstico entrenados con los datos de 2015 a 2025. Elegimos un modelo SARIMA con estacionalidad y cambios de nivel, que tuvo un error promedio de 21.7 accidentes por mes (6.0%) en el periodo de prueba y que capta las variaciones entre meses. El modelo pronostica alrededor de 3,980 accidentes para 2026, entre 305 y 356 por mes.



Palabras clave: accidentes de tránsito, pronóstico, series de tiempo, SARIMA, TDSP, Xalapa.


# Introducción

Los accidentes de tránsito son parte del día a día en Xalapa. Quienes vivimos aquí conocemos el tráfico de la ciudad, sus calles con pendientes y las horas en que todo se satura. Aun así, no existe una herramienta pública que ayude a anticipar cuántos accidentes podrían ocurrir en los próximos meses.

En este trabajo buscamos un conjunto de datos abiertos sobre un problema real y le aplicamos la metodología TDSP (Team Data Science Process), propuesta por Microsoft. Elegimos los accidentes de tránsito en Xalapa porque es un tema cercano a nosotras, con datos públicos del INEGI, y porque sus resultados podrían ser útiles para las autoridades y para la ciudadanía.

Nuestro objetivo es construir la primera versión de un "observatorio de riesgo vial": una herramienta que describa cómo se comportan los accidentes en la ciudad y que pronostique cuántos habrá cada mes. El documento sigue las cinco fases de TDSP, desde la definición del problema hasta la validación de los resultados.

## Marco teórico: la metodología TDSP

TDSP (Team Data Science Process) es una metodología creada por Microsoft y lanzada en 2016 para que los equipos de ciencia de datos trabajen de forma colaborativa y ágil.
Combina el ciclo de vida de la ciencia de datos con prácticas de la ingeniería de software y de los procesos ágiles.

Aunque está muy ligada a Microsoft Azure, puede aplicarse con cualquier herramienta; en nuestro caso usamos RStudio.

A diferencia de CRISP-DM, TDSP define ocho roles dentro del equipo. Como somos dos integrantes, nos los repartimos de la siguiente manera:

| Rol | Qué hace | Quién lo realizó |
|---|---|---|
| Científico de datos (Data Scientist) | Diseña, entrena y evalúa los modelos de pronóstico | Vanessa Méndez |
| Ingeniero de datos (Data Engineer) | Obtiene, limpia y prepara los datos para el análisis | Vanessa Méndez |
| Analista de datos (Data Analyst) | Explora los datos, hace las gráficas e interpreta los patrones | Vanessa Rivera |
| Ingeniero de aprendizaje automático (Machine Learning Engineer) | Convierte el modelo en scripts reproducibles que se pueden actualizar | Vanessa Méndez |
| Propietario de producto (Product Owner) | Representa las necesidades del cliente y define qué debe ofrecer el observatorio | Vanessa Rivera |
| Experto en procesos (Process Expert) | Conoce el contexto del problema (el tránsito en Xalapa) y revisa que los resultados tengan sentido | Vanessa Rivera |
| Gestor de proyecto (Project Manager) | Planea el cronograma y da seguimiento a las entregas de cada fase | Vanessa Rivera |
| Jefe de equipo (Team Manager) | Coordina al equipo, reparte las tareas y supervisa el proyecto | Vanessa Rivera |

Ciclo de vida. Tiene cinco etapas que pueden repetirse las veces necesarias, y son las que seguimos en este trabajo:

1. Comprensión del negocio.
2. Adquisición y comprensión de los datos.
3. Modelado.
4. Despliegue.
5. Aceptación del cliente.

**Fase 1: Comprensión del negocio**

En esta fase definimos el problema, las preguntas que queremos responder, a quién le serviría el proyecto y cómo sabremos si salió bien. Todo esto forma la carta de proyecto.

**Planteamiento del problema**

En Xalapa no hay una herramienta pública que pronostique cuántos accidentes de tránsito ocurrirán en los próximos meses. Por eso, los operativos y las campañas de prevención se planean con base en lo que ya pasó, sin saber qué esperar. Si se contara con un pronóstico, sería posible anticipar los meses con más accidentes y prepararse con tiempo.

**Preguntas de investigación**

1. ¿Cuántos accidentes de tránsito se esperan cada mes en Xalapa durante los próximos meses?
2. ¿Qué patrones siguen los accidentes en la ciudad a lo largo del tiempo y en qué días y horas se concentran?

**Objetivos**

**Objetivo general:** desarrollar la primera versión de un observatorio de riesgo vial para Xalapa que pronostique la cantidad mensual de accidentes de tránsito, siguiendo la metodología TDSP.

**Objetivos específicos:**

1. Integrar una serie mensual de accidentes de tránsito de Xalapa con datos abiertos del INEGI.
2. Describir los patrones de los accidentes, incluido un "reloj del riesgo" que muestre los días y horas con más accidentes.
3. Construir y comparar modelos de pronóstico y elegir el que tenga menor error.
4. Presentar los resultados en un reporte o dashboard que se pueda actualizar con datos nuevos.

**Cliente y beneficiarios**

El cliente principal sería la Dirección de Tránsito y Seguridad Vial de Xalapa, que podría usar el pronóstico para planear operativos y campañas. También se beneficiarían Protección Civil, que podría preparar recursos para los meses de mayor riesgo; la Universidad Veracruzana y otras escuelas, que podrían hacer campañas de seguridad vial para estudiantes; y la ciudadanía en general.

**Alcance**

El proyecto incluye el conteo total de accidentes por mes en Xalapa entre 2015 y 2025, sin distinguir su gravedad, el análisis de patrones por día, hora, mes y año, la comparación de modelos de pronóstico y un reporte o dashboard. No incluye el análisis de víctimas, la ubicación geográfica de los accidentes, datos de clima o eventos, ni otros municipios.

**Fase 2: Adquisición y comprensión de los datos**

En esta fase conseguimos los datos, revisamos su calidad y los exploramos con gráficas para entender cómo se comportan los accidentes en Xalapa.

**Obtención de los datos**

Los datos los obtuvimos de la consulta interactiva de Accidentes de Tránsito Terrestre en Zonas Urbanas y Suburbanas (ATUS) del INEGI, que tiene información de 1997 a 2025. Al principio intentamos trabajar con la base completa, pero era tan pesada que nuestras computadoras no podían abrirla. Por eso usamos la consulta interactiva, que nos permitió filtrar solo el municipio de Xalapa y descargar tablas ya resumidas en Excel, sin perder la información que necesitábamos.

Descargamos tres conjuntos de datos del periodo 2015–2025:

| Conjunto | Contenido | Para qué lo usamos |
|---|---|---|
| Serie mensual | Accidentes por mes y año (132 meses) | Pronóstico (fase 3) |
| Reloj del riesgo | Accidentes por hora, día de la semana y año (7 archivos, uno por día) | Ver en qué días y horas hay más accidentes |
| Tipo de accidente | Accidentes por tipo y año | Ver qué tipos de accidente son más comunes |

Los archivos los procesamos en R con los paquetes readxl, data.table y ggplot2. Siguiendo la estructura estandarizada que propone TDSP, organizamos el proyecto en carpetas separadas para los datos originales, los datos procesados y los resultados.

**Calidad de los datos**

Revisamos que no faltara ningún mes y comprobamos que los totales por año del reloj del riesgo coincidieran con los de la serie mensual. En los 11 años los números fueron exactamente iguales (por ejemplo, 800 en 2015 y 4,065 en 2025), así que los datos son consistentes.

Lo más importante que encontramos es que la serie tiene saltos muy bruscos que después se mantienen (Figura 1). En octubre de 2017 los accidentes pasaron de 72 a 327 en un solo mes, y en julio de 2024 de 133 a 272. Nos parece poco probable que los accidentes reales se tripliquen de un mes a otro y se queden así; creemos que lo más probable es que haya cambiado la forma en que las autoridades registran o reportan los accidentes al INEGI. Sin embargo, no podemos comprobarlo con estos datos, así que lo dejamos como hipótesis. También se ve una caída fuerte en abril de 2020 por la pandemia, y después de ella la serie ya no volvió al nivel anterior.

| Periodo | Promedio de accidentes al mes | ¿Qué pasó? |
|---|---|---|
| Ene 2015 – Sep 2017 | 74 | Inicio de la serie |
| Oct 2017 – Mar 2020 | 257 | Salto de 72 a 327 accidentes |
| Abr 2020 – Jun 2024 | 154 | Caída por la pandemia que ya no se recuperó |
| Jul 2024 – Dic 2025 | 325 | Salto de 133 a 272 accidentes |

**¿Cómo han cambiado los accidentes con el tiempo?**

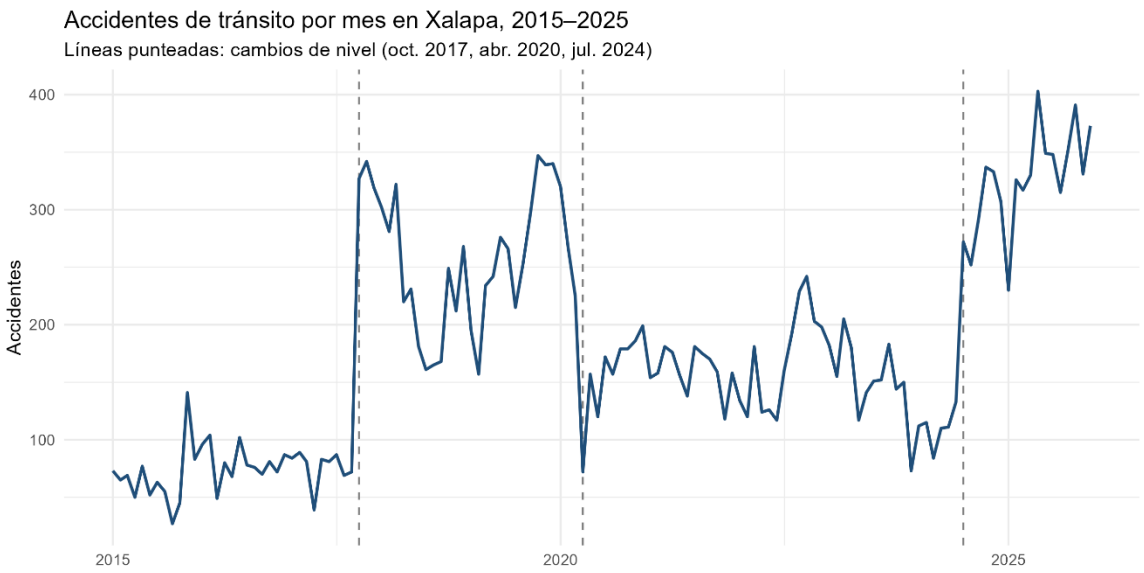



*Figura 1. Accidentes de tránsito por mes en Xalapa, 2015–2025*

En la Figura 1 se ve que la serie no crece poco a poco, sino que cambia de nivel en los saltos que mencionamos. Además, dentro de cada periodo los accidentes suben y bajan bastante: por ejemplo, entre 2018 y 2019 hubo meses con alrededor de 160 accidentes y otros con más de 300.

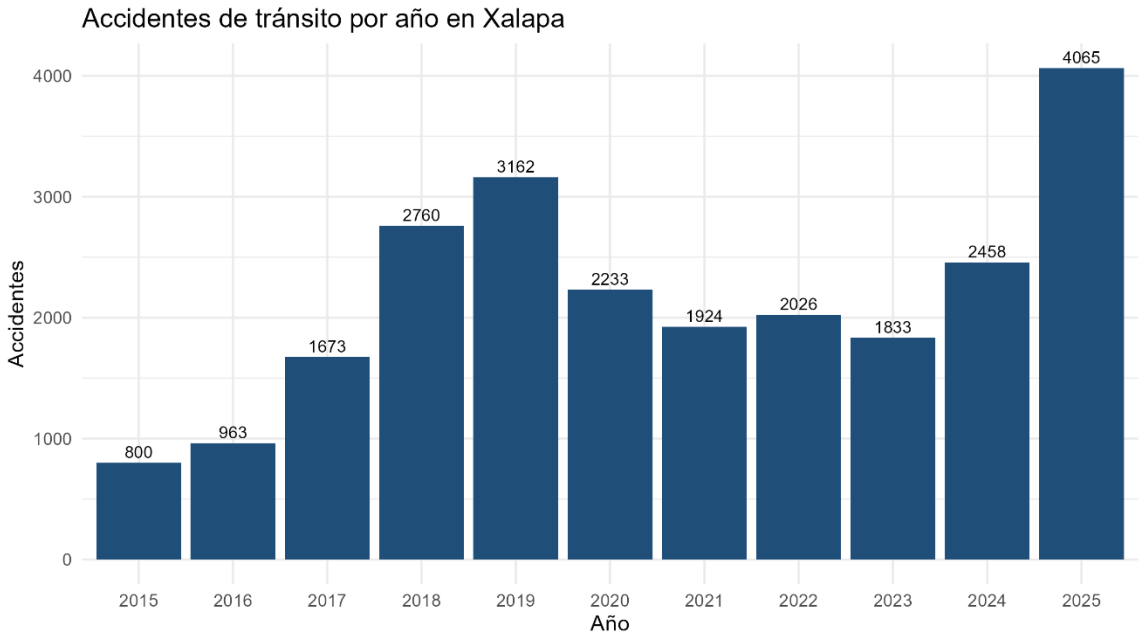



*Figura 2. Accidentes de tránsito por año en Xalapa*

En la Figura 2 vemos que 2015 fue el año con menos accidentes (800) y 2025 el que tuvo más (4,065). También destacan 2019, con 3,162, y la baja de 2020 a 2023, cuando hubo entre 1,833 y 2,233 accidentes por año.

## ¿Hay meses con más accidentes?

Para comparar los meses sin que los saltos nos confundieran, dividimos los accidentes de cada mes entre el promedio de su año (si el valor es 1, el mes estuvo en el promedio). Dejamos fuera 2017, 2020 y 2024, que son los años en que hubo saltos.

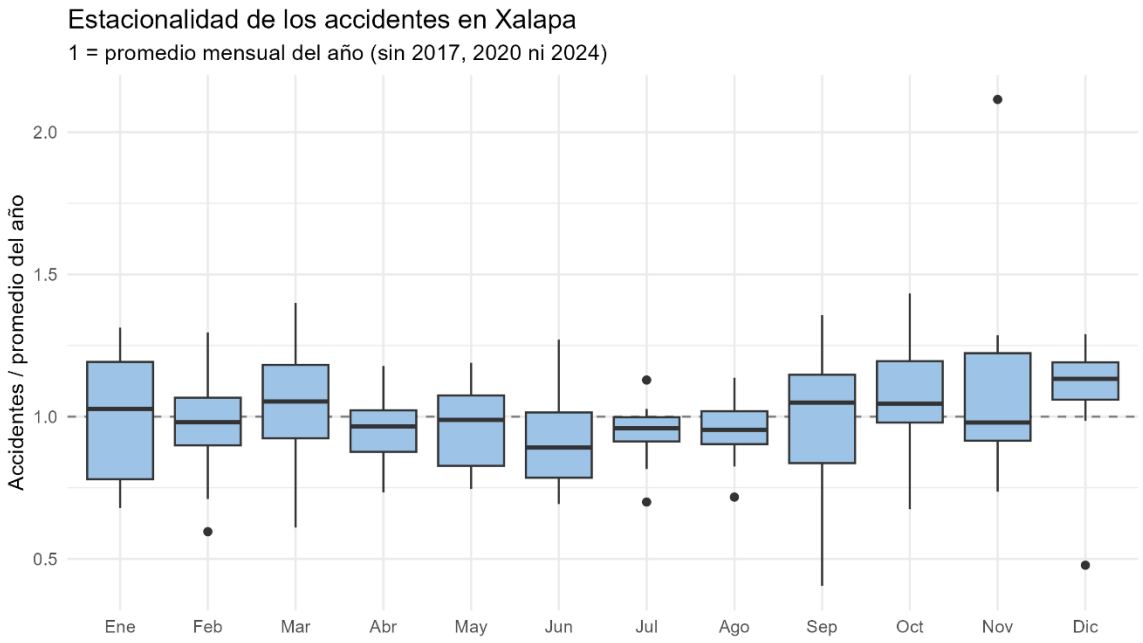



*Figura 3. Estacionalidad de los accidentes en Xalapa*

En la Figura 3 se ve que el patrón por mes es débil. Diciembre suele estar un poco arriba del promedio (alrededor de 13% más) y junio un poco abajo (alrededor de 11% menos), pero las cajas de todos los meses se enciman mucho y cambian bastante de un año a otro. Por eso no podemos decir que haya meses claramente más peligrosos que otros.

## El reloj del riesgo

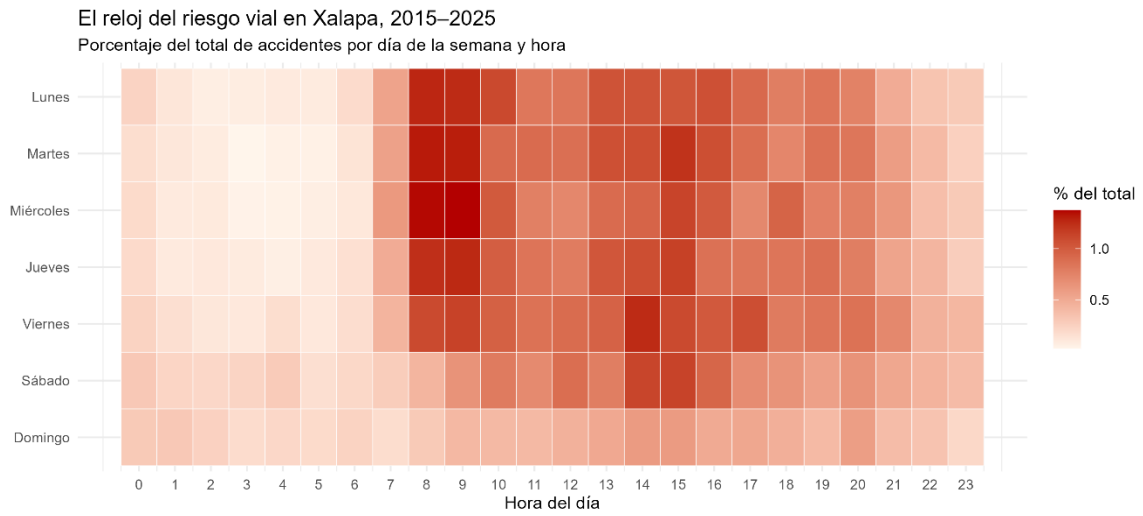



*Figura 4. El reloj del riesgo vial en Xalapa, 2015–2025*

La Figura 4 muestra qué porcentaje de todos los accidentes ocurrió en cada combinación de día y hora. Los colores más oscuros están de lunes a viernes entre las 8 y las 9 de la mañana, y otra vez entre las 14 y las 15 horas, que son las horas de entrada y salida de escuelas y trabajos. El cuadro más oscuro de todos es el miércoles a las 9. Los viernes y sábados el momento con más accidentes es a las 14 horas. En cambio, el domingo tiene colores claros todo el día, y de lunes a viernes las madrugadas (de 2 a 5) casi no tienen accidentes.

En total, de lunes a viernes cada día concentra entre 15% y 16% de los accidentes, el sábado 13% y el domingo solo 9%.

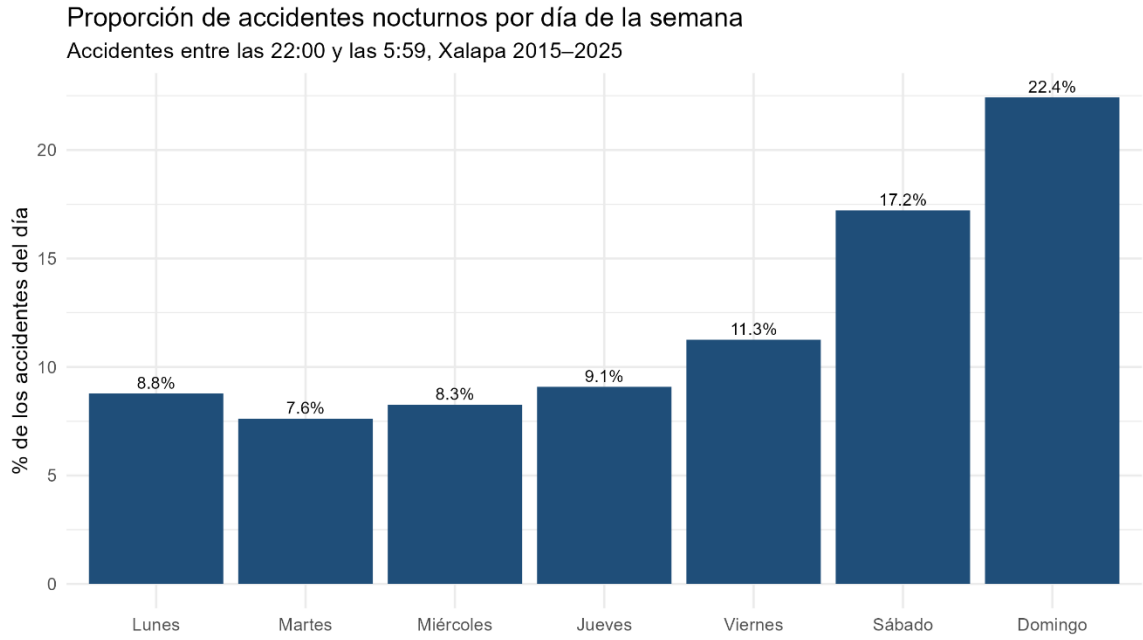



*Figura 5. Proporción de accidentes nocturnos por día de la semana*

Aunque el domingo tiene menos accidentes, la Figura 5 muestra que es el día en que una mayor parte de ellos ocurre de noche: el 22.4% de sus accidentes pasan entre las 22:00 y las 5:59, seguido del sábado con 17.2%. De lunes a jueves esa proporción es de apenas 7.6% a 9.1%. Esto podría estar relacionado con las salidas nocturnas de fin de semana.

**Tipos de accidente**

El tipo de accidente más común por mucho es el choque entre vehículos automotores, que pasó de 61.2% del total en 2015 a 74.8% en 2025. Por eso lo dejamos fuera de la Figura 6, para poder ver mejor los demás tipos.

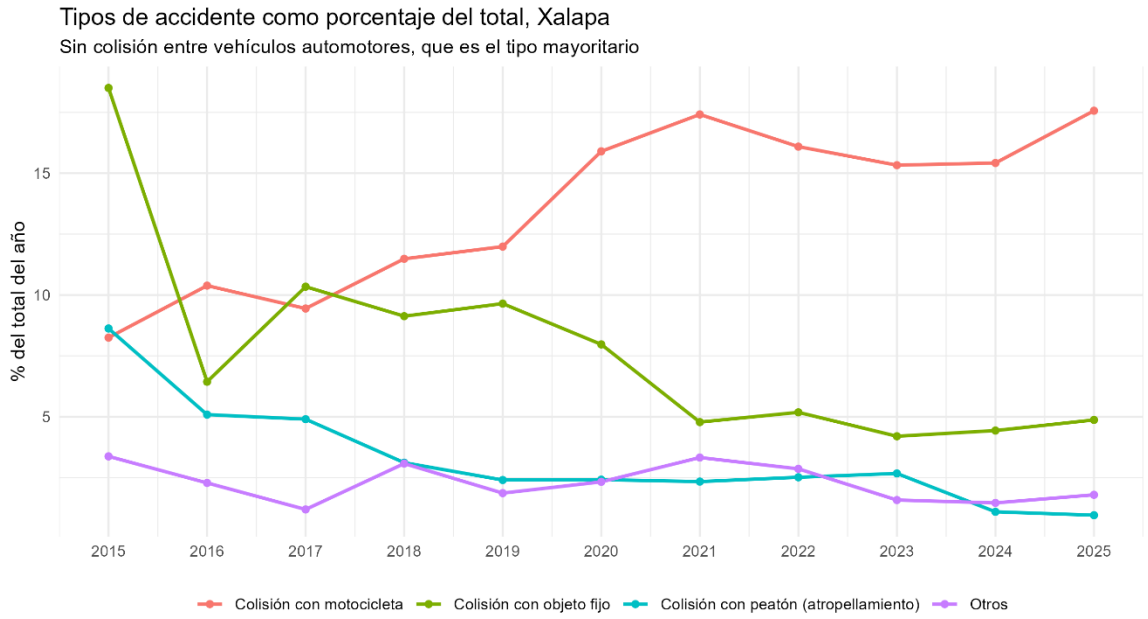



*Figura 6. Tipos de accidente como porcentaje del total, Xalapa*

| Tipo de accidente | 2015 (%) | 2019 (%) | 2025 (%) |
|---|---|---|---|
| Colisión con vehículo automotor | 61.2 | 74.1 | 74.8 |
| Colisión con motocicleta | 8.2 | 12.0 | 17.6 |
| Colisión con objeto fijo | 18.5 | 9.6 | 4.9 |
| Colisión con peatón (atropellamiento) | 8.6 | 2.4 | 1.0 |
| Otros | 3.4 | 1.9 | 1.8 |

En la Figura 6 se ve que las colisiones con motocicleta fueron ganando peso: de 8.2% en 2015 subieron y se mantuvieron entre 15% y 18% de 2020 a 2025, y en 2025 fueron el segundo tipo más común. En cambio, los choques contra objetos fijos bajaron de 18.5% a 4.9%, y los atropellamientos de 8.6% a 1.0%. Usamos porcentajes y no cantidades porque

las cantidades están afectadas por los saltos en el registro, aunque es posible que parte de estos cambios también se deba a cambios en la forma de clasificar los accidentes.

**¿Qué significa esto para el modelo?**

Los datos sí nos permiten responder nuestras preguntas, pero el modelo tiene que "saber" dónde están los saltos para no confundirlos con aumentos reales. Por eso, en la fase 3:

- Incluiremos tres cambios de nivel en el modelo: octubre de 2017, abril de 2020 y julio de 2024. El de 2020 lo tomamos como permanente porque la serie nunca regresó al nivel anterior a la pandemia.
- Como 2025 está en un nivel que empezó a mitad de 2024, entrenaremos el modelo con los datos de enero de 2015 a junio de 2025 y lo probaremos con los meses de julio a diciembre de 2025.
- Como el patrón por mes es débil, compararemos modelos con y sin estacionalidad.

También reconocemos algunas limitaciones: no podemos confirmar por qué ocurrieron los saltos, los datos solo incluyen los accidentes que se reportaron a las autoridades (puede haber subregistro) y no sabemos si cambió la forma de clasificar los tipos de accidente.

**Fase 3: Modelado**

En esta fase construimos varios modelos de pronóstico, los comparamos y elegimos el que se equivocó menos.

**Preparación**

A partir de lo que encontramos en la fase 2, creamos tres variables que le indican al modelo dónde hubo cambios de nivel en la serie: octubre de 2017, abril de 2020 y julio de 2024. Después dividimos los datos en dos partes: entrenamos los modelos con los 126 meses de enero de 2015 a junio de 2025 y guardamos los meses de julio a diciembre de 2025 para probarlos, es decir, para ver qué tanto se equivocaban con datos que no habían visto. Así, todos los modelos aprendieron de toda la serie desde 2015 y no solo de los años más recientes.

**Modelos que comparamos**

Comparamos siete modelos. En algunos dejamos que el programa decidiera si agregaba un patrón que se repite cada año (estacionalidad) y en otros lo incluimos de forma obligatoria, para comprobar si ese patrón mejoraba el pronóstico:

1. **M1. Ingenuo estacional:** repite el valor del mismo mes del año anterior. Es el punto de comparación: si un modelo no le gana a este, no sirve.
2. **M2. Suavizamiento exponencial automático (ETS):** da más peso a los meses recientes, por lo que se adapta rápido a los cambios de nivel. El programa decide si agrega tendencia o estacionalidad.

3. **M3. Suavizamiento exponencial con estacionalidad:** igual que el anterior, pero obligado a incluir un patrón mensual.
4. **M4. ARIMA con cambios de nivel:** modelo de series de tiempo que incluye las tres variables de cambio de nivel.
5. **M5. SARIMA automático con cambios de nivel:** igual que el anterior, pero el programa puede agregar estacionalidad si le conviene.
6. **M6. SARIMA con estacionalidad forzada y cambios de nivel:** un SARIMA obligado a incluir la parte estacional, que además usa las variables de cambio de nivel.
7. **M7. SARIMA clásico (0,1,1)(0,1,1)[12]:** el modelo estacional más usado en los libros de series de tiempo, sin variables de cambio de nivel.

Para medir los errores usamos tres métricas: el MAE (cuántos accidentes se equivoca en promedio), el RMSE (parecido al MAE, pero castiga más los errores grandes) y el MAPE (el error en porcentaje).

**Resultados**

| **Modelo** | **Especificación** | **MAE** | **RMSE** | **MAPE (%)** |
|---|---|---|---|---|
| M2. ETS automático | ETS(A,N,N) | 21.7 | 25.5 | 6.3 |
| M6. SARIMA con estacionalidad forzada y cambios de nivel | ARIMA(2,0,0)(2,1,0)[12] con cambios de nivel | 21.7 | 29.7 | 6.0 |
| M4. ARIMA con cambios de nivel | ARIMA(1,0,0) con cambios de nivel | 34.8 | 42.6 | 9.5 |
| M5. SARIMA automático con cambios de nivel | ARIMA(1,0,0) con cambios de nivel | 34.8 | 42.6 | 9.5 |
| M3. ETS con estacionalidad | ETS(A,N,A) | 49.7 | 54.0 | 14.5 |
| M1. Ingenuo estacional | Mismo mes del año anterior | 53.5 | 58.6 | 15.2 |
| M7. SARIMA clásico | ARIMA(0,1,1)(0,1,1)[12] | 74.4 | 77.2 | 21.6 |

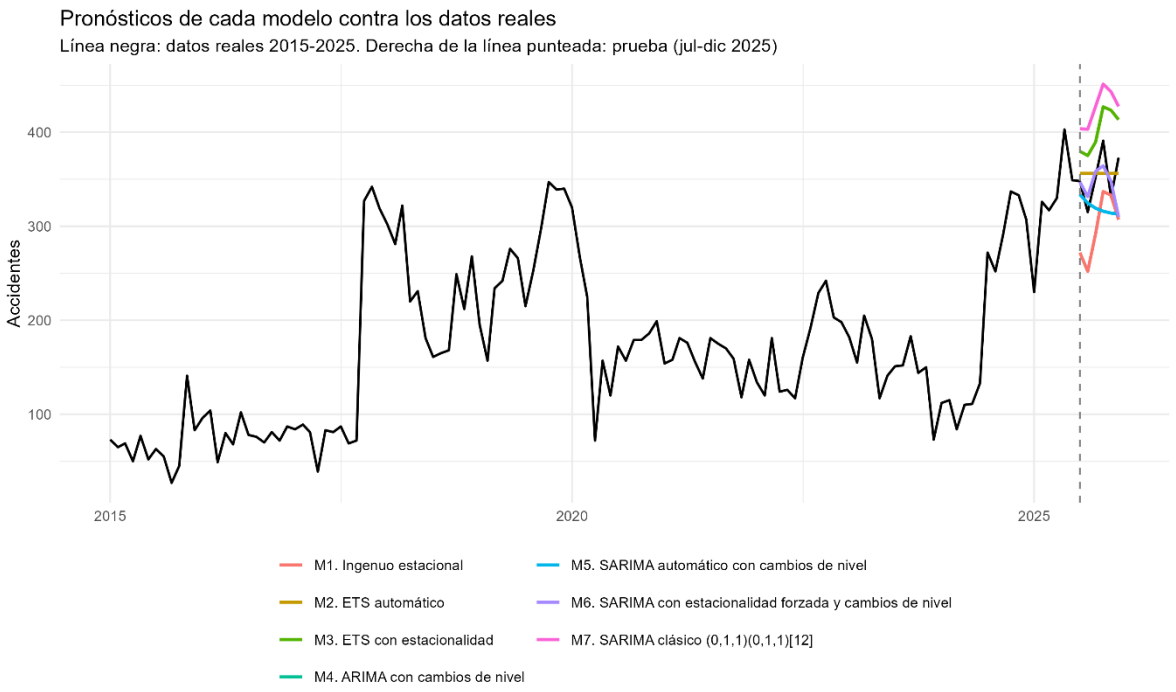



*Figura 7. Pronósticos de cada modelo contra los datos reales, 2015–2025*

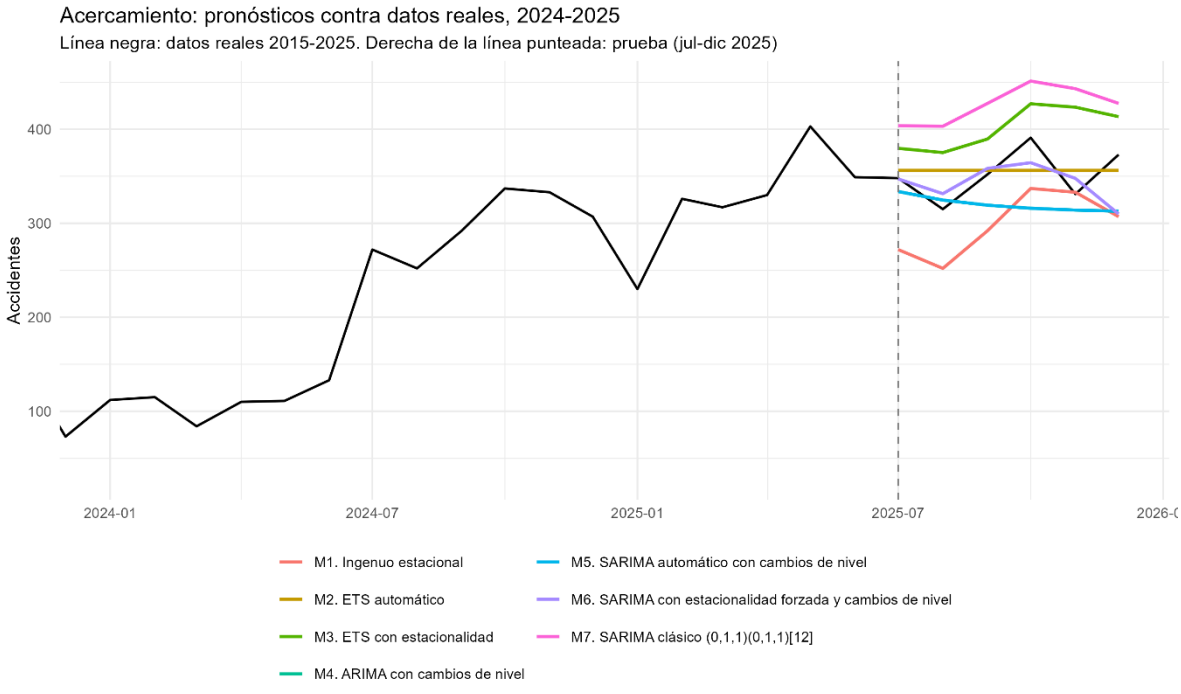



*Figura 8. Acercamiento al periodo de prueba, 2024–2025*

Los dos mejores modelos fueron el suavizamiento exponencial automático (M2) y el SARIMA con estacionalidad forzada (M6), que empataron con un error promedio de 21.7 accidentes por mes. El M6 tuvo un error porcentual un poco menor (6.0% contra 6.3%),

mientras que el M2 tuvo un RMSE menor (25.5 contra 29.7), lo que indica que el M6 tuvo algún mes con un error más grande.

En la Figura 8 se ve la diferencia entre ambos. El M2 pronosticó un valor constante de unos 357 accidentes para todos los meses, mientras que el M6 bajó en agosto y subió en septiembre y octubre, igual que los datos reales, aunque en noviembre y diciembre se desfasó: en diciembre pronosticó unos 310 accidentes y en realidad hubo 373.

Los modelos que agregaban estacionalidad sin las variables de cambio de nivel, o de forma rígida, se equivocaron más. El ETS con estacionalidad (M3) y el SARIMA clásico (M7) sobreestimaron los accidentes, con pronósticos de más de 400 en varios meses, y el M7 fue el peor de todos. El M4 y el M5 dieron exactamente el mismo resultado, porque el SARIMA automático decidió no agregar estacionalidad; por eso la línea del M4 no se ve en las figuras, ya que queda debajo de la del M5.

**Elección del modelo final**

Elegimos el SARIMA con estacionalidad forzada y cambios de nivel (M6) como modelo final por cuatro razones: empató con el menor error promedio y tuvo el menor error porcentual; capta las subidas y bajadas entre meses, en lugar de dar un solo valor para todo el año; usa directamente los cambios de nivel que encontramos en la fase 2; y, como se ve en la Figura 9, su pronóstico tiene un margen de error mucho más pequeño que el del suavizamiento exponencial.

**Pronóstico para 2026**

Volvimos a entrenar el M6 con todos los datos, de enero de 2015 a diciembre de 2025, y pronosticamos los 12 meses de 2026.

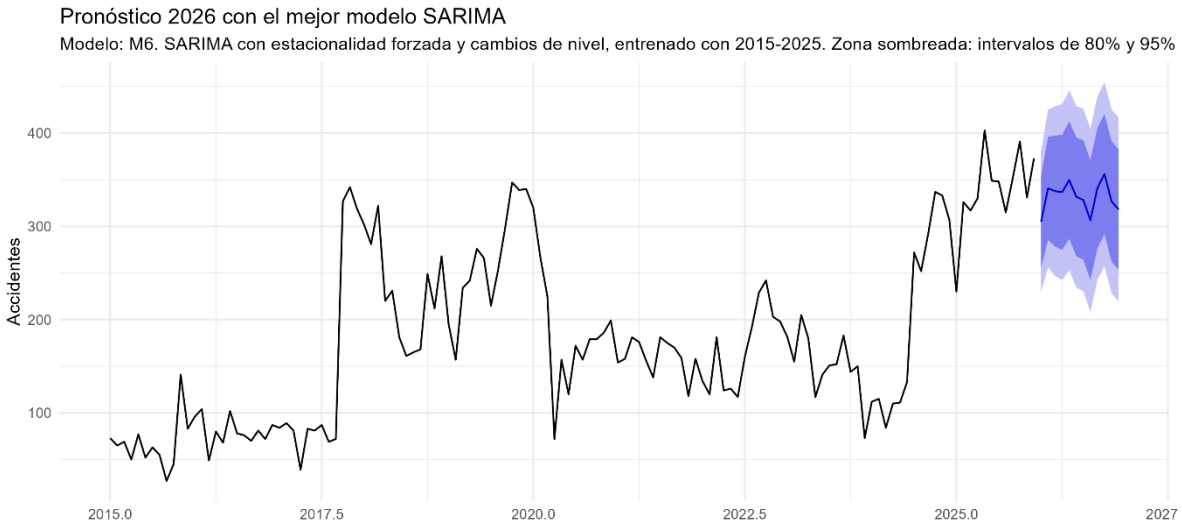



*Figura 9. Pronóstico de accidentes de tránsito en Xalapa para 2026 con el modelo SARIMA*

| Mes | Accidentes pronosticados | Mes | Accidentes pronosticados |
|---|---|---|---|
| Enero | 305 | Julio | 328 |
| Febrero | 341 | Agosto | 307 |
| Marzo | 338 | Septiembre | 341 |
| Abril | 337 | Octubre | 356 |
| Mayo | 350 | Noviembre | 327 |
| Junio | 332 | Diciembre | 318 |

El modelo pronostica entre 305 y 356 accidentes por mes, alrededor de 3,980 en todo 2026, una cifra parecida a los 4,065 de 2025. Los meses con más accidentes serían octubre (356) y mayo (350), y los de menos, enero (305) y agosto (307).

Las zonas sombreadas de la Figura 9 muestran la incertidumbre del pronóstico: con 95% de confianza, los accidentes de cada mes estarían aproximadamente entre 210 y 455. Este margen es mucho más estrecho que el del suavizamiento exponencial, cuyo rango para diciembre iba de 110 a 624, por lo que el pronóstico del SARIMA es más útil para planear.

Como comparación, el suavizamiento exponencial pronosticaba un valor constante de 367 accidentes por mes (unos 4,404 en el año). Ambos modelos coinciden en que el nivel de accidentes de 2026 será parecido al de 2025.

Una advertencia importante: este pronóstico supone que la forma de registrar los accidentes se mantiene igual. Si vuelve a ocurrir un salto como los de 2017 o 2024, el pronóstico dejaría de ser válido y habría que actualizarlo.

**Fase 4: Despliegue**

En TDSP, el despliegue consiste en poner la solución a disposición de quien la va a usar. Como este es un proyecto escolar y no contamos con un servidor ni con un convenio con el Ayuntamiento, nuestro despliegue es un **reporte reproducible**: un conjunto de archivos que cualquier persona puede descargar, correr y actualizar.

**¿Qué entregamos?**

| Producto | Archivo | Para qué sirve |
|---|---|---|
| Script de la fase 2 | fase2_comprension_datos.R | Lee los archivos del INEGI, revisa su calidad y genera las gráficas del reloj del riesgo y de los tipos de accidente |
| Script de la fase 3 | fase3_modelado.R | Compara los modelos, elige el mejor y pronostica los siguientes 12 meses |

| Producto | Archivo | Para qué sirve |
|---|---|---|
| Tabla de pronóstico | pronostico_2026.csv | Accidentes esperados por mes, con su límite inferior y superior |
| Gráficas | Carpeta resultados/graficas | Las ocho figuras de este documento |

Todo está organizado en un proyecto de RStudio con carpetas separadas para los datos originales, los datos procesados y los resultados, como recomienda TDSP.

**¿Cómo se actualiza el observatorio?**

Cada año, cuando el INEGI publique los datos nuevos, basta con:

1. Descargar de nuevo las tablas de Xalapa desde la consulta interactiva del INEGI.
2. Guardarlas en la carpeta datos/crudos y cambiar el año final en los scripts.
3. Correr los dos scripts para obtener las gráficas y el pronóstico del año siguiente.

**¿Cómo lo usaría el cliente?**

Con la tabla de pronóstico, la Dirección de Tránsito podría saber cuántos accidentes esperar cada mes y planear el número de agentes y operativos. Con el reloj del riesgo podría concentrar esos operativos en las horas pico de los días hábiles (8–9 h y 14–15 h) y reforzar la vigilancia nocturna los fines de semana.

Como mejora a futuro, estos mismos resultados podrían convertirse en un dashboard interactivo en Shiny, donde se puedan consultar las gráficas sin necesidad de saber programar.

**Fase 5: Aceptación del cliente**

En esta última fase revisamos si el proyecto cumplió con lo que nos propusimos en la carta de proyecto. Como no trabajamos directamente con la Dirección de Tránsito, hicimos esta validación nosotras mismas, comparando los resultados con nuestras métricas de éxito y nuestras preguntas de investigación.

**¿Cumplimos las métricas de éxito?**

| Métrica | Resultado | ¿Se cumplió? |
|---|---|---|
| Error de pronóstico | El SARIMA elegido tuvo un MAE de 21.7, contra 53.5 del ingenuo estacional | Sí, se equivocó menos de la mitad |
| Comparación de modelos | Comparamos siete modelos y justificamos la elección del SARIMA | Sí |

| Métrica | Resultado | ¿Se cumplió? |
|---|---|---|
| Reproducibilidad | Los scripts corren completos de principio a fin | Sí, aunque para un año nuevo hay que ajustar las fechas en los scripts |
| Entrega | Completamos las cinco fases | Sí |

**¿Respondimos las preguntas de investigación?**

**1. ¿Cuántos accidentes se esperan cada mes en Xalapa?** Según nuestro modelo SARIMA, entre 305 y 356 accidentes por mes en 2026, unos 3,980 en el año, con menos accidentes en enero y agosto y más en mayo y octubre.

**2. ¿Qué patrones siguen los accidentes?** Encontramos que la serie cambia de nivel en saltos bruscos más que crecer poco a poco, que las diferencias entre meses son pequeñas, que los accidentes se concentran de lunes a viernes a las 8–9 h y a las 14–15 h, y que los fines de semana una mayor parte ocurre de noche. Además, las colisiones con motocicleta han ganado peso dentro del total.

**Limitaciones**

- No pudimos confirmar si los saltos de 2017 y 2024 se deben a cambios en el registro; si vuelve a pasar algo así, el pronóstico tendría que actualizarse.
- Los datos solo incluyen los accidentes reportados a las autoridades, así que puede haber subregistro.
- Probamos los modelos con solo seis meses, porque el nivel actual de la serie empezó a mitad de 2024. Con más datos la evaluación sería más confiable.
- La validación la hicimos nosotras y no un cliente real.

Aun con estas limitaciones, consideramos que el proyecto cumple con su objetivo: tenemos una primera versión funcional del observatorio que describe los accidentes de Xalapa y pronostica cuántos habrá cada mes.

**Conclusiones**

Con este trabajo logramos aplicar la metodología TDSP a un problema real de nuestra ciudad, desde definir el problema hasta obtener un pronóstico y revisar si cumplía con lo que buscábamos. Nuestro modelo final, un SARIMA con estacionalidad y cambios de nivel, estima alrededor de 3,980 accidentes de tránsito en Xalapa para 2026, y el reloj del riesgo muestra que la mayoría ocurre en días hábiles a las horas de entrada y salida de escuelas y trabajos.

Uno de los aprendizajes más importantes fue que los datos no siempre cuentan la historia que parece a simple vista. Al principio pensamos que los accidentes en Xalapa habían crecido mucho, pero al revisar la serie mes por mes descubrimos saltos que probablemente se deben a cambios en el registro y no a cambios reales. Si no los hubiéramos detectado en la fase 2,

el modelo habría dado resultados engañosos. Esto nos hizo ver por qué TDSP le da tanta importancia a entender los datos antes de modelar.

También comprobamos lo útil que es que TDSP sea iterativo. Durante el proyecto tuvimos que regresar varias veces a fases anteriores: cambiamos de tema, ajustamos el enfoque, cambiamos la forma de descargar los datos porque la base completa era demasiado pesada, modificamos el plan de modelado después de explorar los datos y, siguiendo la retroalimentación de nuestra docente, ampliamos la comparación a siete modelos, incluidos varios SARIMA. En lugar de ser un problema, esos ajustes forman parte natural de la metodología. Además, la definición de roles nos ayudó a repartir el trabajo aun siendo solo dos integrantes.

Como trabajo a futuro, el observatorio podría crecer agregando la ubicación de los puntos con más accidentes, datos de clima o días festivos, el efecto del calendario escolar y un dashboard interactivo.

**Referencias**


- Instituto Nacional de Estadística y Geografía (INEGI). (2026). *Accidentes de tránsito terrestre en zonas urbanas y suburbanas: consulta interactiva de datos* [Base de datos]. https://www.inegi.org.mx/sistemas/olap/proyectos/bd/continuas/transporte/accidentes.asp
- Microsoft. (s. f.). *What is the Team Data Science Process?* Microsoft Learn. https://learn.microsoft.com/en-gb/azure/architecture/data-science-process/overview
- Microsoft. (s. f.). *The Team Data Science Process lifecycle*. Microsoft Learn. https://learn.microsoft.com/fi-fi/azure/architecture/data-science-process/lifecycle
- Microsoft Azure. (s. f.). *Azure-TDSP-ProjectTemplate* [Repositorio de GitHub]. https://github.com/Azure/Azure-TDSP-ProjectTemplate